A decorative graphic on the left side of the slide consisting of two overlapping parallelograms. The front one is blue and the back one is a light green color. They are positioned diagonally, with the blue one partially covering the green one.

Projektpräsentation: Klassifizierung von Maiskrankheiten

Dario Cantore




Struktur

1. Einführung und Motivation
2. Explorative Datenanalyse
3. Modellergebnisse
4. Conclusion
5. Appendix




① Einführung und Motivation

- Fortschritt und wachsende Bevölkerungen basieren auf ausreichender und sicherer Versorgung durch Grundnahrungsmittel
- In der Vergangenheit hat dies zu zielgerichteter Züchtung spezifischer, effizienterer Sorten verschiedener Grundnahrungsmittel geführt die sich immer stärker ausgebreitet haben
- Dies führt allerdings zu immer größer werdendem Risiko sollten ehemals effiziente Sorten bedroht werden - wie bei Bananen bereits der Fall¹
- Um Ausbreitung zu vermeiden müssen Krankheiten in bestehenden Populationen effizient entdeckt werden um Behandlung so schnell wie möglich zu ermöglichen



Die folgende Projektarbeit wird sich auf Mais fokussieren, ein weiteres Nahrungsmittel das sich mehr und mehr auf eine Sorte fokussiert ("Dent" / "Field corn"), welches bereits von Krankheiten befallen wird die sich durch Wind alleine verbreiten - eine effektive Identifizierung ist essentiell um Verbreitung auf weitere Felder zu vermeiden



Es werden Deep Learning Algorithmen verwendet um Bilder von gesundem und infizierten Mais zu klassifizieren und Landwirten (mittels Kameras an Traktoren) eine frühe und effiziente Identifizierung zu ermöglichen.


1: <https://time.com/5730790/banana-panama-disease/>

② Explorative Datenanalyse (1/2)

- Der Datensatz wird von Kaggle zur Verfügung gestellt²
- Er enthält in verschiedenen Ordnern Bilder von gesundem, "yellow rust" infiziertem, sowie "brown rust" infiziertem Mais
- In einem ersten Schritt werden wir die Daten Laden, Beispielbilder anzeigen, und die Datenfrequenz analysieren

Wie untenstehend sichtbar sind alle 3 Klassen (Brown rust / Healthy / Yellow rust) meist menschlich erkennbar, es gibt allerdings auch menschlich schwer klassifizierbare Bilder (siehe z.B. Healthy)

Brown rust



Healthy




Yellow rust



② Explorative Datenanalyse (2/2)

- Der Datensatz enthält insgesamt ca. 3.600 Bilder³
- Diese wurden in ein Training, Test, und Validation dataset gesplittet
- Wie untenstehend ersichtlich, sind die 3 Klassen relativ ausgewogen vorhanden und kein Over-/Undersampling ist nötig



3: Alle Bilder wurden von Keras auf dieselbe Auflösung gescaled (256x256 Pixel)

③ Modellergebnisse (1/3)

- Mithilfe von Keras wurde ein sequentielles Modell mit ca. 60 Tausend Neuronen gefittet
- Das Modell enthält Data Augmentation, Rescaling-, Convolutional 2D-, und Pooling Layer – die Pooling layer mit 4x4 Pools
- Die Output layer ist eine Dense-layer mit 3 Neuronen (eins pro Klasse) und der Softmax Aktivierungsfunktion
- Zudem wurde eine Learning-rate von 0,001 benutzt - die Learning rate hatte von allen Parametern den mit Abstand stärksten Einfluss auf Konvergenz
- Es hat sich insbesondere gezeigt, dass Modelle mit > 1 Millionen Parametern zum overfitten neigen - “kleinere” Modelle (ca. 100.000 Parameter) waren besser auf dem Validierungsdatensatz

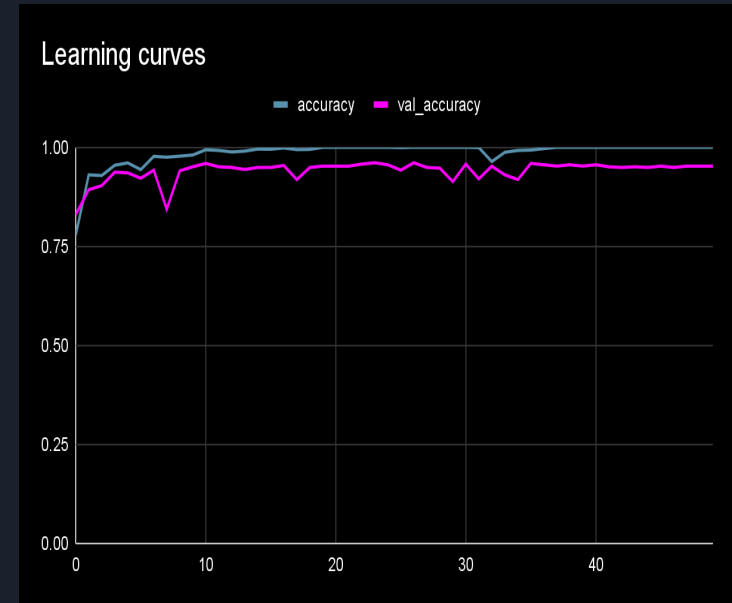
```
Model: "sequential"
Layer (type)                Output Shape                Param #
-----
Rescaling                    (None, 256, 256, 3)         0
Random Flip                  (None, 256, 256, 3)         0
conv2d_24 (Conv2D)           (None, 254, 254, 16)        448
MaxPooling                   (None, 63, 63, 16)          0

conv2d_25 (Conv2D)           (None, 61, 61, 32)          4640
conv2d_26 (Conv2D)           (None, 59, 59, 64)          18496
MaxPooling                   (None, 14, 14, 64)          0
flatten_8 (Flatten)          (None, 12544)               0
dense_8 (Dense)              (None, 3)                   37635

Total params: 61,219
Trainable params: 61,219
Non-trainable params: 0
```

③ Modellergebnisse (2/3)

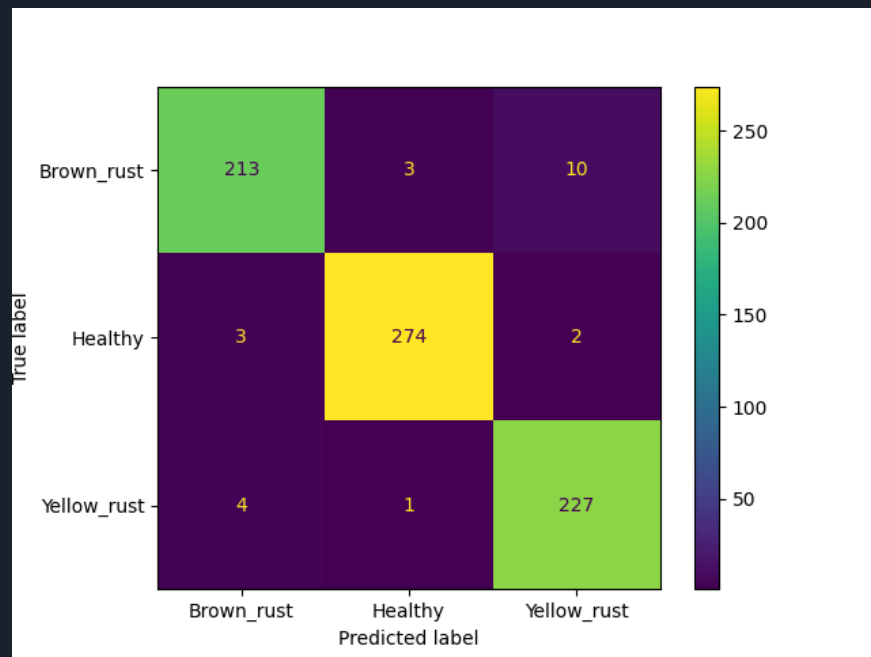
- Die finale accuracies auf dem Training, Test ("val_accuracy") und Validierungsdatenset sind $\geq 95\%$
- Finale accuracies⁴:
 - Training: 97%
 - Test: 95%
 - Validation: 97%
- Mit den gegebenen Parametrisierungen und Modell scheint sich ein zufriedenstellendes Modell zu ergeben



4: Zusätzliche Analysen mit mehr Epochen, zusätzlichen Pooling Layer, sowie Data Augmentation wurden durchgeführt - ohne materielle Unterschiede in den Ergebnissen

③ Modellergebnisse (3/3)

- Auch die Konfusionsmatrix auf dem Validierungsset bestätigen die Ergebnisse
- Insbesondere sind “false healthy”, der “schlimmere” Fehler da krankens Mais übersehen wird, gering (mit insgesamt nur 4 solchen Fehlern, oder ca. 0.5%)
- Die Modellparametrisierung benötigt daher auch keine zusätzlichen Fehler- oder Klassengewichtungen



③ Inkorrekt klassifizierte Bilder

- Beim Vergleich inkorrekt klassifizierter Bilder zu ihren Labels zeigen sich 2 verschiedene Fälle:
 - Teilweise (ca. 30% der misklassifizierten Fälle, 10 Bilder) sind die “true label” falsch zugewiesen, siehe z.B. oben links
 - Teilweise sind die Labelvorhersagen aber auch falsch z.B. unten Mitte
- Das Modell scheint Mais also in >97% der Fälle korrekt zu klassifizieren und auch von falsch zugewiesenen Labels nicht beeinträchtigt zu werden

Beispielbilder mit “True” und vorhergesagten Labels





④ Conclusion

1. Keras erlaubt die einfache Parametrisierung von Deep-Learning Modellen
2. Selbst relativ einfache, “selbst” gebaute Modelle von Keras erlauben akkurate Identifikation von krankem Mais und den zugehörigen Krankheiten
3. Insbesondere große Landwirtschaftsbetriebe können von Machine Learning zur frühen Identifikation von krankem Mais profitieren, da Landwirte insbesondere in frühen Stadien Krankheiten übersehen
4. In einem möglichen nächsten Schritt könnte daher eine Implementierung in Machine Vision erfolgen, um Kameras von z.B. Erntetraktoren oder Düngedrohnen die Identifizierung von Krankheiten zu ermöglichen und substanziellen Schaden zu vermeiden




Danke für die Aufmerksamkeit



?

Gibt es Fragen?

Appendix



Beispielbilder und vorhersagen



Auch bei nichttrivialen Bildern (z.B. geringe Auflösung) prognostiziert das Deep-learning Modell die korrekte Klasse